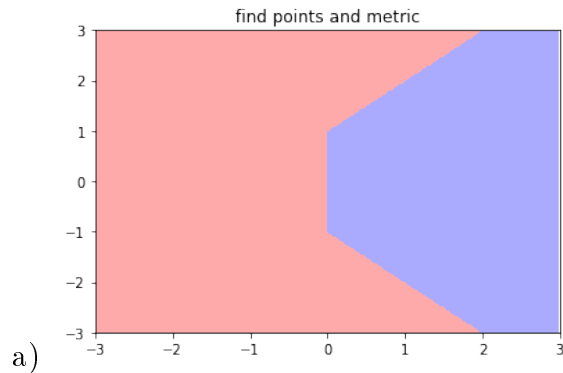



### Домашнее задание №1

1. Пусть объекты  $(0,1)$  и  $(0, -1)$  принадлежат одному классу, а объект  $(2, 0)$  — другому. Получить аналитическую формулу разделяющей поверхности для метода одного ближайшего соседа с  $\ell_2$  метрикой.
2. Решить предыдущую задачу для  $\ell_1$  метрики.
3. Привести пример обучающего и тестового множества минимальной мощности, для которых при  $k > 1$ :
  - (а) метод 1-ближайшего соседа даёт точность на тесте больше, чем метод  $k$ -ближайших соседей,
  - (б) метод  $k$ -ближайших соседей даёт точность на тесте больше, чем метод 1-ближайшего соседа.
4. Привести пример обучающего и тестового множества минимальной мощности, для которых при  $k > 1$ :
  - (а) обычный метод  $k$ -ближайших соседей даёт точность на тесте больше, чем метод  $k$ -ближайших взвешенных соседей (веса, например, обратно пропорциональны расстояниям),
  - (б) метод  $k$ -ближайших взвешенных соседей даёт точность на тесте больше, чем обычный метод  $k$ -ближайших соседей.
5. Для метода классификации одного ближайшего соседа получились следующие разделяющие поверхности. Привести пример обучающего множества и метрики, на которых метод мог бы выучить такое разделяющее правило.





6. Опишите преимущества и недостатки k-fold валидации и LOO валидации. Приведите примеры, когда предпочтительнее использовать LOO вместо 5-fold валидации, и наоборот.
7. Для объектов  $x_1, \dots, x_n$  с правильными ответами  $y_1, \dots, y_n$  из  $\mathbb{R}$  постройте константную модель  $a(x) = c$  для функции потерь:
  - a)  $MSE$  (mean squared error)  $= \frac{1}{N} \sum_{i=1}^n (y_i - c)^2$ ;
  - b)  $MAE$  (mean absolute error)  $= \frac{1}{N} \sum_{i=1}^n |y_i - c|$ .
8. Для объектов  $x_1, \dots, x_n$  с правильными ответами  $y_1, \dots, y_n$  из  $\{0, 1\}$  постройте наилучшую константную классификационную модель  $a(x) = c$  для функции потерь бинарной перекрёстной энтропии.
9. Для объектов  $x_1, \dots, x_n$  из  $\mathbb{R}$  с правильными ответами  $y_1, \dots, y_n$  из  $\mathbb{R}$  постройте наилучшую константную модель  $a(x) = kx + b$  для функции потерь

$$MSE \text{ (mean squared error)} = \frac{1}{N} \sum_{i=1}^n (y_i - kx_i - b)^2.$$

10. Пусть дана обучающая выборка  $(x_1, y_1), \dots, (x_n, y_n)$ , где пара  $(x_i, y_i)$  — объект и правильный ответ, причем  $x_i \in \mathbb{R}^2$ , а  $y_i \in \{0, 1\}$ . Известно, что распределение для обоих классов — гауссовское с параметрами:  $\mu_0 = (a, b)^T$ ,  $\mu_1 = (-a, -b)^T$ ,  $\Sigma_0 = \Sigma_1 = \text{diag}(\sigma_1, \sigma_2)$ . Выпишите байесовский алгоритм классификации и уравнение разделяющей поверхности.

11. Доказать, что наивный байесовский классификатор в случае бинарных признаков  $f_i \in \{0, 1\}$  является линейным разделителем:

$$a(x) = a(f_1, \dots, f_n) = [a_0 + a_1 f_1 + \dots + a_n f_n > 0].$$

Выведите формулы для коэффициентов  $a_i$ .